

Podstawy Sztucznej Inteligencji

Przewidywanie okresu wypowiedzenia umowy na podstawie
danych klientów w celu zwiększenia zysku ze świadczenia usług

22 Kwietnia 2026

Bartosz Bodulski
Informatyka Techniczna

Maciej Gładysiak
Informatyka Techniczna

SPIS TREŚCI

Kamień Milowy 1	2
Problem	2
Cel Projektu	2
Wymagania:	2
Kamień Milowy 2	3
Opis	3
Wykresy	6
Kamień Milowy 3	9
Opis	9
Model 1: XGBoost (Extreme Gradient Boosting)	9
Model 2: Głęboka Sieć Neuronowa (PyTorch)	10
Wyniki	11
Opis Metryk	14
Ogólne Porównanie	14
Kamień Milowy 4	15
Wprowadzone zmiany	15
Zmiana samplingu danych	15
Zmniejszenie progu funkcji aktywacji ChurnNeuralNet	15
Zastąpienie BCEWithLogitsLoss przez FocalLoss	16
XGBoost - Opuszczenie najmniej ważnych cech	16

KAMIEŃ MIŁOWY 1

PROBLEM

Problem polega na przewidywaniu czasu, po którym dany klient zamierza zakończyć umowę z firmą zajmującą się telekomunikacją. Chcemy ten czas jak najbardziej przedłużyć w celu maksymalizacji dochodów pochodzących ze świadczenia usług internetowych (telewizja, internet światłowodowy itp.)

CEL PROJEKTU

Efektywna kampania marketingowa (predykcja za pomocą algorytmu sztucznej inteligencji), mająca na celu proponowanie klientom lepsze warunki umowy / promocje w przewidzianym okresie, w którym dany klient ma duże prawdopodobieństwo na odstąpienie od niej.

WYMAGANIA:

- Zestaw danych dotyczący umów klientów, w szczególności zawierający dane o okresie czasu, po którym klient rozwiązał umowę ([LINK - Wersja 2017](#)) ([Wersja 2019](#))
- Skalowalność: Wzrost rozmiaru danych wejściowych w realistycznych proporcjach nie powinien zwiększać gwałtownie czasu wykonania modelu.
- Bezpieczeństwo: Model nie powinien ujawniać w żaden sposób danych wrażliwych pochodzących od klientów.

PROJEKTY MOŻNA, A NAWET POLECAM ROBIĆ W PARACH.

1. **Określenie tematu i celu projektu, analiza wymagań**
 - a. **Opis:** Zdefiniowanie celu projektu, zakresu, oraz wymaganych zasobów do wdrożenia AI. Określenie problemu, który ma zostać rozwiązany przy użyciu sztucznej inteligencji oraz zebranie wymagań (np. wydajność, skalowalność, bezpieczeństwo).
 - b. **Oczekiwany wynik:** Jasno określony cel projektu, dokumentacja wymagań.
2. **Zbiór danych i ich przygotowanie**
 - a. **Opis:** Zbieranie, czyszczenie i wstępna analiza danych, które będą wykorzystane do treningu modeli AI. Może to obejmować pozyskanie danych z różnych źródeł, normalizację, usuwanie brakujących lub błędnych danych oraz ich transformację.
 - b. **Oczekiwany wynik:** Przygotowany zestaw danych, gotowy do wykorzystania w procesie uczenia maszynowego.
3. **Wybór i implementacja modelu AI**
 - a. **Opis:** Wybór odpowiedniego algorytmu AI oraz implementacja modelu. Może to obejmować prototypowanie różnych podejść i testowanie ich wydajności na przygotowanych danych.
 - b. **Oczekiwany wynik:** Zbudowany i przetestowany model AI, gotowy do oceny.
4. **Ocena wyników modelu i optymalizacja**
 - a. **Opis:** Dobór metryk. Testowanie modelu na zestawie danych testowych w celu oceny jego dokładności, wydajności, oraz ogólnych wyników. Optymalizacja modelu np. przez dostosowanie hiperparametrów, selekcję cech lub poprawę jakości danych.
 - b. **Oczekiwany wynik:** Zoptymalizowany model AI osiągający wymagane parametry wydajności.
5. **Wdrożenie modelu i monitorowanie**
 - a. **Opis:** Przeniesienie modelu do środowiska produkcyjnego i integracja z otoczeniem. Ustalenie mechanizmów monitorowania.
 - b. **Oczekiwany wynik:** Zaimplementowany i uruchomiony system z AI w konkretnym środowisku.

Rysunek 1: Wybrane przez nas kamienie milowe

KAMIEŃ MIŁOWY 2

OPIS

Wybrany zbiór danych przedstawia bazę klientów fikcyjnej firmy telekomunikacyjnej. Głównym celem pracy z tymi danymi jest przewidywanie, który klient zrezygnuje z usług firmy / po jakim czasie zakończy on umowę z firmą (czyli przewidywanie zjawiska Churn). Aby łatwiej było go zrozumieć, te 21 kolumn można podzielić na 4 logiczne kategorie:

1. Dane demograficzne (Kim jest klient?)

- CustomerID: Unikalny identyfikator klienta (np. 7590-VHVEG). Z punktu widzenia analityki ignoruje się go, bo nie niesie żadnej wiedzy.
- gender: Płeć klienta (Male - Mężczyzna, Female - Kobieta).
- SeniorCitizen: Czy klient jest seniorem? Wartość liczbowa: 1 oznacza Tak, 0 oznacza Nie.
- Partner: Czy klient ma małżonka/partnera? (Yes/No).
- Dependents: Czy klient ma osoby na utrzymaniu (np. dzieci)? (Yes/No).

2. Wykupione usługi (Z czego korzysta klient?)

- PhoneService: Czy klient ma telefon stacjonarny? (Yes/No).
- MultipleLines: Czy klient ma wiele linii telefonicznych? (Yes/No/No phone service).
- InternetService: Rodzaj łącza internetowego. Może to być DSL (standardowe łącze), Fiber optic (szybki światłowód) lub No (brak internetu).
- Dodatkowe usługi internetowe (Jeśli klient ma internet, może dobrać te opcje - przyjmują wartości Yes / No / No internet service):
- OnlineSecurity: Dodatkowe zabezpieczenia sieciowe.
- OnlineBackup: Usługa kopii zapasowej w chmurze.
- DeviceProtection: Ubezpieczenie/ochrona sprzętu (np. routera).
- TechSupport: Priorytetowe wsparcie techniczne.
- StreamingTV: Usługa telewizji przez internet.
- StreamingMovies: Usługa VOD (filmy na życzenie).

3. Informacje o koncie i płatnościach (Jak klient płaci?)

- Tenure (Staż): Bardzo ważna kolumna. Liczba miesięcy, przez które klient jest z firmą (np. 1 oznacza nowego klienta, 45 to lojalny klient od prawie 4 lat).
- Contract: Rodzaj umowy:
- Month-to-month (z miesiąca na miesiąc - ci klienci najszybciej odchodzą),
- One year (umowa na rok),
- Two year (umowa na dwa lata).
- PaperlessBilling: Czy klient zrezygnował z rachunków papierowych na rzecz elektronicznych? (Yes/No).
- PaymentMethod: Metoda płatności (np. Electronic check - czek elektroniczny, Mailed check - czek pocztowy, Bank transfer - przelew, Credit card - karta kredytowa).
- MonthlyCharges: Miesięczna kwota rachunku w dolarach (np. \$29.85).
- TotalCharges: Suma wszystkich opłat, jakie klient wniósł od początku trwania umowy (w przybliżeniu $\text{tenure} * \text{MonthlyCharges}$). To właśnie tę kolumnę musimy modyfikować, bo u zupełnie nowych klientów (tenure = 0) to pole było w pliku puste (spacja) zamiast zera.

4. Zmienna docelowa (Cel analizy)

Churn: odpowiada na pytanie: „Czy w ciągu ostatniego miesiąca ten klient zrezygnował z usług firmy?”

- Yes - Klient oszedł (Strata dla firmy).
- No - Klient został.

WA_Fn-UseC_-Telco-Customer-Churn.csv (977.5 kB) ↓ [] >

Detail **Compact** Column 10 of 21 columns ▾

▲ customerID ▾	▲ gender ▾	# SeniorCitiz... ▾	✓ Partner ▾	✓ Dependents ▾	# tenure ▾	✓ PhoneServ... ▾
7590-VHVEG	Female	0	Yes	No	1	No
5575-GNVDE	Male	0	No	No	34	Yes
3668-QPYBK	Male	0	No	No	2	Yes
7795-CFOCW	Male	0	No	No	45	No

Rysunek 2: Wybrane dane i nagłówki kolumn ze zbioru danych

Za czyszczenie danych w naszym kodzie odpowiada funkcja `load_and_clean_data()`. Załączamy kod funkcji;

Funkcja ta:

- Wczytuje .csv naszych danych
- Usuwa kolumnę `customerID`, która jest zbędna na potrzeby naszej analizy
- Zamienia wszystkie puste pola (" ") na NaN, które następnie są zmieniane na 0
- Mapuje kolumnę `Churn` z "Yes" i "No" na odpowiednio 1 i 0
- Mapuje wartości na zmienne liczbowe - one-hot encoding
- Castuje wszystkie wartości na typ `zmiennoprzecinkowy`

```
def load_and_clean_data(filepath):
    print(f"Reading data from: {filepath}")
    df = pd.read_csv(filepath)

    if 'customerID' in df.columns:
        df = df.drop(columns=['customerID'])

    # empty cells -> NaN -> 0
    df['TotalCharges'] =
pd.to_numeric(df['TotalCharges'].replace(" ",
np.nan))
    df['TotalCharges'] =
df['TotalCharges'].fillna(0)

    # map main variable to {0,1}
    df['Churn'] = df['Churn']
        .map({'Yes': 1, 'No': 0})

    # one-hot encoding

    df = pd.get_dummies(df, drop_first=True)

    # cast everything needed to float

    df = df.astype(float)

    return df
```

Przeczyszczone dane są następnie przekazywane do funkcji `prepare_data_splits()`:

```
def prepare_data_splits(df):
    X = df.drop(columns=[TARGET_COLUMN]).values
    y = df[TARGET_COLUMN].values

    # Divide the data into train,test,validate subsets
    X_temp, X_test, y_temp, y_test = train_test_split(
        X, y, test_size=TEST_SIZE, random_state=RANDOM_STATE, stratify=y
    )

    val_ratio = VAL_SIZE / (1.0 - TEST_SIZE)
    X_train, X_val, y_train, y_val = train_test_split(
        X_temp, y_temp, test_size=val_ratio, random_state=RANDOM_STATE, stratify=y_temp
    )
```

```

# scale data for NNs
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_val = scaler.transform(X_val)
X_test = scaler.transform(X_test)

return (X_train, y_train), (X_val, y_val), (X_test, y_test)

```

Funkcja dzieli dane na trzy zbiory: zbiór treningowy, zbiór walidacyjny i zbiór testowy.

```

class ChurnDataset(Dataset):
    def __init__(self, X, y):

        self.X = torch.tensor(X, dtype=torch.float32)

        # For binary classification pytorch need something like (n,1) instead of just (n)

        self.y = torch.tensor(y, dtype=torch.float32).unsqueeze(1)

    def __len__(self):
        return len(self.y)

    def __getitem__(self, idx):
        return self.X[idx], self.y[idx]

def get_dataloaders():

    df = load_and_clean_data(RAW_DATA_PATH)

    feature_names = df.drop(columns=[TARGET_COLUMN]).columns.tolist()

    #save modified data to temporary file

    df.to_csv(PROCESSED_DATA_PATH, index=False)

    (X_train, y_train), (X_val, y_val), (X_test, y_test) = prepare_data_splits(df)

    # Dataloaders for python

    train_loader = DataLoader(ChurnDataset(X_train, y_train), batch_size=BATCH_SIZE,
shuffle=True, drop_last=True)
    """drop_last=True fixes the Expected more than 1 value per channel when training, got
input size torch.Size([1, 64])"""
    val_loader = DataLoader(ChurnDataset(X_val, y_val), batch_size=BATCH_SIZE, shuffle=False)
    test_loader = DataLoader(ChurnDataset(X_test, y_test), batch_size=BATCH_SIZE,
shuffle=False)


    # XGboost dictionary for the selected training sets
    xgb_data = {
        "X_train": X_train, "y_train": y_train,
        "X_val": X_val, "y_val": y_val,
        "X_test": X_test, "y_test": y_test,
        "feature_names": feature_names # <--- this is for the xgboost plot file
    }

    # we return input_dims here
    input_dim = X_train.shape[1]
    return train_loader, val_loader, test_loader, xgb_data, input_dim


```

Podzielone dane następnie są owijane w DataLoader (do pytorch) czy zwracane w słowniku xgb_data (do xgboosta)


WYKRESY




Rysunek 3: Wykres słupkowy zmiennej Churn




Rysunek 4: Boxplot opłat miesięcznych



Rysunek 5: Churn w zależności od typu kontraktu



Rysunek 6: Heatmap zależności wybranych zmiennych



Rysunek 7: Zależność między opłatami miesięcznymi a zmienną Churn - Histogram

1. Wykres słupkowy (Distribution of Churn - Rysunek 3) - Balans klas:

Co widać: 5174 klientów pozostało w firmie, a 1869 zrezygnowało. Wniosek: Rezygnację (churn) dotyczą około 26 - 27% klientów. Zbiór danych jest „niezbalansowany” (więcej lojalnych niż odchodzących), co później wymusi zmianę wag tych zmiennych w kodzie dla sieci XGBoost.

1. Wykres pudełkowy (Monthly charges vs churn - Rysunek 4) - Opłaty miesięczne:

Co widać: Pudełko dla odchodzących (Yes - czerwone) leży zauważalnie wyżej niż dla zostających (No - zielone). Wniosek: Klienci, którzy rezygnują z usług, mają zazwyczaj wyższe miesięczne rachunki (mediana ok. 80), niż ci którzy zostają (mediana ok. 65). Wyższe koszty sprzyjają ucieczce do konkurencji.

2. Pogrupowane słupki (Contract type vs churn risk - Rysunek 5) - Rodzaj umowy

Co widać: Ogromna czerwona kolumna (Yes) przy umowach „Month-to-month”. Prawie brak czerwieni przy umowach na 2 lata. Wniosek: Klienci bez długoterminowego zobowiązania (z miesiąca na miesiąc) odchodzą masowo. Podpisanie umowy na rok lub dwa drastycznie zmniejsza ryzyko utraty klienta.

3. Mapa cieplna (Correlation matrix - Rysunek 6) - Korelacje liczbowe

Co widać: Współczynniki zależności. Na przykład na przecięciu tenure i Churn_Num mamy współczynnik korelacji równy -0.35 . Wniosek: Istnieje ujemna korelacja między stażem a odejściem. Oznacza to, że im dłużej ktoś jest z firmą (wyższe tenure), tym mniejsze prawdopodobieństwo, że zrezygnuje.

4. Histogram ze stosami (Monthly Charges vs Churn - Rysunek 7) Co widać: “Duża fioletowa wieża” (zostający przy kwocie \$20) oraz “szeroka różowa góra” (odchodzący w przedziale \$70-\$105). Wniosek: Uzupełnia to wykres pudełkowy. Firma ma ogromną rzeszę lojalnych klientów, którzy płacą bardzo mało (prawdopodobnie utrzymują najtańszą, podstawową usługę). Problem rezygnacji dotyczy głównie klientów o średnich i wysokich rachunkach.

KAMIEŃ MIŁOWY 3

OPIS

W ramach projektu zdecydowano się na podejście hybrydowe, implementując dwa niezależne modele, aby porównać skuteczność algorytmów drzewiastych z sieciami neuronowymi w zadaniu klasyfikacji binarnej (Churn: Tak/Nie).

Zaimplementowane modele:

- Konfiguracja XGBClassifier (XGBoost).
- Klasa ChurnNeuralNet (PyTorch).

MODEL 1: XGBOOST (EXTREME GRADIENT BOOSTING)

Dlaczego: Jest to obecnie jeden z najskuteczniejszych algorytmów dla danych tabelarycznych.

Świetnie radzi sobie z brakującymi danymi i nieliniowymi zależnościami.

- **Kluczowe cechy implementacji:**
 - Zastosowano **skalowanie wag klas (scale_pos_weight=2.76)**, aby zaradzić nierównowadze w zbiorze danych (więcej osób zostaje w sieci, niż z niej odchodzi).
 - Ustawiono parametry zapobiegające overfittingowi: max_depth=4, subsample=0.8 oraz learning_rate=0.05.
- **Plik:** src/models/xgboost_model.py

```
import xgboost as xgb

def get_xgboost_model():
    """
    Initializes and returns an XGBoost model ready for training.
    """
    # We calculate the class weight based on plot 1:
    # (Number of customers staying / Number leaving) = approx. 5174 / 1869 ≈ 2.76
    # This will help the model handle the minority class (churned customers) better

    model = xgb.XGBClassifier(
        n_estimators=100, # Number of decision trees
        max_depth=4, # Maximum tree depth (prevents overfitting)
        learning_rate=0.05, # Learning rate
        subsample=0.8, # Uses 80% of data to build each tree
        colsample_bytree=0.8, # Uses 80% of features to build each tree
        scale_pos_weight=2.76, # Class balancing!
        eval_metric="logloss", # Evaluation metric during training
        random_state=42, # Ensures reproducibility
        n_jobs=-1, # Uses all CPU cores
    )

    return model
```

MODEL 2: GŁĘBOKA SIEĆ NEURONOWA (PYTORCH)

Dlaczego: Pozwala na wychwycenie bardzo złożonych, ukrytych korelacji między cechami, które mogą umknąć algorytmom drzewiastym.

- **Architektura (zaimplementowana w ChurnNeuralNet)**

- **Warstwy:** Wejściowa -> 64 neurony -> 32 neurony -> Wyjściowa (1 neuron).
- **Regularyzacja:** Zastosowano warstwy **Dropout** (30% i 20%) oraz **Batch Normalization**, aby model był stabilny i nie „uczył się na pamięć” danych treningowych.
- **Funkcja aktywacji:** ReLU dla warstw ukrytych.

- **Plik:** src/models/xgboost_model.py

```
import torch
import torch.nn as nn

class ChurnNeuralNet(nn.Module):
    def __init__(self, input_dim):
        super(ChurnNeuralNet, self).__init__()

        # Define the network architecture
        self.network = nn.Sequential(
            # Input layer
            nn.Linear(input_dim, 64),
            nn.BatchNorm1d(64),
            nn.ReLU(),
            nn.Dropout(0.3), # Randomly disables 30% of neurons to prevent memorization

            # Hidden layer
            nn.Linear(64, 32),
            nn.BatchNorm1d(32),
            nn.ReLU(),
            nn.Dropout(0.2),

            # Output layer
            # 1 neuron, because we are doing binary classification (output is churn
probability)
            nn.Linear(32, 1)
        )

    def forward(self, x):
        # Data passes through the network
        # We do not use a Sigmoid layer here, because in PyTorch we will use
        # BCEWithLogitsLoss, which is more numerically stable and includes Sigmoid internally!
        return self.network(x)
```

Logika treningu (src/core/trainer.py)

- Zaimplementowano ustandaryzowaną pętlę treningową z użyciem optymalizatora **Adam** oraz funkcji straty **BCEWithLogitsLoss** (idealna dla klasyfikacji binarnej w PyTorch).

WYNIKI

```
After training (PyTorch):

=====
Layer (type:depth-idx)                   Output Shape          Param #
=====
ChurnNeuralNet                          [32, 1]               --
├─Sequential: 1-1                        [32, 1]               --
│   └─Linear: 2-1                        [32, 64]              1,984
│       └─BatchNorm1d: 2-2               [32, 64]              128
│           └─ReLU: 2-3                  [32, 64]              --
│               └─Dropout: 2-4           [32, 64]              --
│                   └─Linear: 2-5        [32, 32]              2,080
│                       └─BatchNorm1d: 2-6 [32, 32]              64
│                           └─ReLU: 2-7   [32, 32]              --
│                               └─Dropout: 2-8 [32, 32]              --
│                                   └─Linear: 2-9 [32, 1]              33
=====
Total params: 4,289
Trainable params: 4,289
Non-trainable params: 0
Total mult-adds (Units.MEGABYTES): 0.14
=====
Input size (MB): 0.00
Forward/backward pass size (MB): 0.05
Params size (MB): 0.02
Estimated Total Size (MB): 0.07
=====
```


Rysunek 8: Kształt modelu z torchinfo summary

Modele są już zintegrowane z systemem metryk (Accuracy, F1-Score, Recall) w głównym skrypcie src/main.py. Wyniki dla obu modeli po podzieleniu datasetu na sekcje 70/15/15 (trening/test/walidacja) wyglądają następująco:


```
Final results (test set)

=====
Metric          | PyTorch (NN)         | XGBoost
-----
Accuracy         | 0.7975                | 0.7540
F1-Score         | 0.5900                | 0.6389
Recall           | 0.5500                | 0.8214
=====
```


Rysunek 9: Wyniki wytrenowanych modeli



Rysunek 10: Confusion matrix dla pytorcha



Rysunek 11: Confusion matrix dla xgboosta



Rysunek 12: Najważniejsze zmienne dla xgboosta

OPIS METRYK

Accuracy (Dokładność)

- **Co mówi:** Jaki procent wszystkich decyzji modelu był poprawny?
- **Wzór:** (Wszystkie dobre decyzje) / (Wszystkie przypadki)

Z danych wynika, że ponad 80% klientów nie kończy umowy z firmą. Model będzie wybierał sztywno tą opcję w celu uzyskania jak największej dokładności i może "okłamywać" resztę analizy. Tej mierze należy ufać tylko, gdy liczba klientów odchodzących i zostających jest mniej więcej równa.

Recall (Czułość / Pełność)

- **Co mówi:** Ile osób z tych, które naprawdę odeszły, nasz model zdołał poprawnie wskazać?
- **Wzór:** (Poprawnie wykryty Churn) / (Wszyscy, którzy faktycznie odeszli)

To jest prawdopodobnie najważniejsza metryka dla działu utrzymania klienta. Jeśli Recall wynosi 0.80, to znaczy, że zidentyfikowaliśmy 80% osób planujących odejście. Pozostałe 20% to „uciekiniery”, których nie zauważyliśmy i niestety straciliśmy. Chcemy, aby Recall był jak najwyższy, żeby nie przegapić żadnego klienta, którego można jeszcze uratować promocją.

F1-Score

- **Co mówi:** To średnia (harmoniczna) z Recall i Precision. Szuka balansu.

Sam wysoki Recall łatwo oszukać. Wystarczy, że model stwierdzi, że każdy dany mu klient odjedzie. Wtedy Recall będzie równy 100%, ale model jest bezużyteczny, bo nie poprawnie klasyfikuje lojalnych klientów, którzy nie chcą kończyć umowy z firmą. F1-Score karze model za bycie zbyt ostrożnym lub zbyt agresywnym. Jeśli F1-Score jest wysoki, oznacza to, że model ma zarówno dobrą wykrywalność (Recall), jak i nie myli się zbyt często (Precision). To najlepsza metryka do ogólnego porównania, czy lepszy tutaj jest XGBoost, czy Sieć Neuronowa.

OGÓLNE PORÓWNANIE

Mimo że sieć neuronowa (PyTorch) ma wyższą ogólną dokładność, to w tym konkretnym zadaniu (przewidywanie odejścia klientów) zdecydowanym zwycięzcą jest XGBoost.

- Accuracy (Dokładność):
 - PyTorch (79,75%) wypada lepiej niż XGBoost (75,40%).
 - Interpretacja: Sieć neuronowa rzadziej się myli ogółem, ale prawdopodobnie wynika to z tego, że jest bardzo „ostrożna” i najczęściej przewiduje, że klient zostanie (bo takich klientów jest w bazie najwięcej).
- Recall (Czułość):
 - XGBoost: (82,14%) przewyższa PyTorch: (55%).
 - Interpretacja: Tutaj jest najważniejsza różnica pomiędzy modelami. XGBoost poprawnie wykrywa aż 82% osób, które faktycznie chcą odejść. Sieć neuronowa wykrywa tylko 55%, czyli prawie połowę uciekających klientów po prostu pomija. Tak wysoki wynik XGBoost to efekt zastosowania w kodzie parametru `scale_pos_weight=2.76`, który „zmusił” model do zwracania większej uwagi na klientów odchodzących.
- F1-Score:
 - XGBoost (63,89%) przewyższa PyTorch (59%).
 - Interpretacja: F1-Score potwierdza, że choć XGBoost częściej się myli (niższe Accuracy), to jego ogólna wartość użytkowa w balansowaniu wykrywania zjawiska „Churnu” w tym zbiorze danych jest większa.

KAMIEŃ MIŁOWY 4

WPROWADZONE ZMIANY

ZMIANA SAMPLINGU DANYCH

w `get_dataloaders.py` zamiast `shuffle=True` zastosowano `WeightedRandomSampler`

```
class_sample_count = np.array([len(np.where(y_train == t)[0]) for t in
np.unique(y_train)])
weight = 1. / class_sample_count # if the ammount of variables in each class is different,
we need to adjust the weight
samples_weight = np.array([weight[int(t)] for t in y_train])

samples_weight = torch.from_numpy(samples_weight).double()
sampler = WeightedRandomSampler(samples_weight, len(samples_weight))

# Dataloaders for python

train_loader = DataLoader(ChurnDataset(X_train, y_train), batch_size=BATCH_SIZE,
shuffle=False, drop_last=True)
# instead of shuffle=True, we use the sampler to ensure balanced sampling, set to True if
results are worse
"""drop_last=True fixes the Expected more than 1 value per channel when training, got
input size torch.Size([1, 64])"""
val_loader = DataLoader(ChurnDataset(X_val, y_val), batch_size=BATCH_SIZE, shuffle=False)
test_loader = DataLoader(ChurnDataset(X_test, y_test), batch_size=BATCH_SIZE,
shuffle=False)
```

Dlaczego:

- W danych o churnie mamy **silnie niebalansowane** klasy - ok. 73% osób pozostaje, tylko ok. 27% osób odchodzi (Wykres - Rysunek 3).
 - `shuffle=True` losuje próbki losowo, ale nie zmienia rozkładu klas - nadal w każdej epoce model widzi **dużo więcej przykładów klasy dominującej**.
 - `WeightedRandomSampler` nadaje wagi próbkom **odwrotnie proporcjonalnie** do liczebności ich klasy. Dzięki temu w każdej epoce model widzi tyle samo przykładów z klasy mniejszościowej, co z większościowej.
- W efekcie model powinien nie ignorować klientów odchodzących, skutkując poprawieniem metryk

ZMNIJSZENIE PRÓGU FUNKCJI AKTYWACJI `ChurnNeuralNet`

Próg został zmniejszony z 0.5 do 0.4.

```
nn_results = evaluate_pytorch(nn_model, test_loader, DEVICE, threshold=0.4)
```

Dlaczego:

- Domyślny 0.5 działa dobrze z założeniem, że klasy są tak samo prawdopodobne - co w naszym przypadku nie jest prawdą.
 - Dla niebalansowanych danych, model często przewiduje niskie prawdopodobieństwo dla klasy mniejszościowej (np. 0.3). Przy progu 0.5 - żadna taka próbka nie zostanie zaklasyfikowana jako "odejście".
 - Obniżenie progu do 0.4 zwiększa czułość (recall), czyli wykrywalność klientów, którzy **faktycznie odeszli**. Kosztem może być nieznaczny wzrost fałszywie pozytywnych, jednakże w

analizowanym przez nas przypadku jest to akceptowalne - **najważniejsze jest, aby nie przegapić klientów którzy faktycznie odejdą.**

ZASTĄPIENIE BCEWithLogitsLoss PRZEZ FocalLoss

W pliku `trainer_pytorch.py` jako kryterium do trenowana zmieniono BCEWithLogitsLoss na FocalLoss

```
criterion = FocalLoss()
# ...

# ...
class FocalLoss(nn.Module):
    def __init__(self, alpha=0.25, gamma=2.0):
        super(FocalLoss, self).__init__()
        self.alpha = alpha
        self.gamma = gamma

    def forward(self, inputs, targets):
        BCE_loss = F.binary_cross_entropy_with_logits(inputs, targets,
reduction="none")
        pt = torch.exp(-BCE_loss)
        F_loss = self.alpha * (1 - pt) ** self.gamma * BCE_loss
        return torch.mean(F_loss)
```

Dlaczego:

- Metoda Focal Loss została zaproponowana do detekcji obiektów w **silnie niezbalansowanych zbiorach**.
 - Redukuje wagę łatwych przykładów (gdzie model jest bardzo pewny klasy większościowej) i skupia się na trudnych, źle sklasyfikowanych przykładach (często należących do klasy mniejszościowej).
- Model uczy się lepiej rozpoznawać rzadkie, ale ważne przypadki churnu, nawet jeśli są one trudniejsze do odróżnienia.

XGBOOST - OPUSZCZENIE NAJMNIEJ WAŻNYCH CECH

XGBoost trenuje model, następnie odrzuca 30% najmniej ważnych cech, po czym następnie trenuje nowy model (pomijając odrzucone cechy).

```
def train_and_eval_xgboost_with_feature_selection(
    xgb_model, xgb_data, drop_percent=30, verbose=False
):
    print("\n--- Starting XGBoost Training with feature selection ---")

    # First training to determine feature importance

    features = xgb_data["feature_names"]
    X_train_df = pd.DataFrame(xgb_data["X_train"], columns=features)
    X_val_df = pd.DataFrame(xgb_data["X_val"], columns=features)
    X_test_df = pd.DataFrame(xgb_data["X_test"], columns=features)

    # Initial training
    xgb_model.fit(
        X_train_df,
        xgb_data["y_train"],
        eval_set=[(X_val_df, xgb_data["y_val"])],
        verbose=False,
    )
```

```

print("XGBoost training finished!")

# Get feature importance
importances = xgb_model.feature_importances_
feature_importance_pairs = list(zip(features, importances))
feature_importance_pairs.sort(key=lambda x: x[1], reverse=True)

# Calculate how many features to keep
n_features = len(features)
n_keep = max(1, int(n_features * (100 - drop_percent) / 100))

# Get top features
top_features = [pair[0] for pair in feature_importance_pairs[:n_keep]]
dropped_features = [pair[0] for pair in feature_importance_pairs[n_keep:]]

if verbose:
    print("\nFeature importance ranking:")
    for i, (feature, imp) in enumerate(feature_importance_pairs[:10], 1):
        print(f"    {i}. {feature}: {imp:.4f}")

    print(f"\nKeeping top {100 - drop_percent}% ({n_keep}/{n_features} features)")

    if dropped_features:
        print(f"\nDropping {len(dropped_features)} low-importance features:")
        for feature in dropped_features[:5]:
            print(f"    - {feature}")
        if len(dropped_features) > 5:
            print(f"    ... and {len(dropped_features) - 5} more")

# Retrain with only top features
# Filter data to keep only top features
feature_indices = [features.index(f) for f in top_features]

X_train_filtered = xgb_data["X_train"][ :, feature_indices]
X_val_filtered = xgb_data["X_val"][ :, feature_indices]
X_test_filtered = xgb_data["X_test"][ :, feature_indices]

# Create new model (fresh training)
from src.models.xgboost_model import get_xgboost_model

xgb_model_filtered = get_xgboost_model()

# Train on filtered data
X_train_filtered_df = pd.DataFrame(X_train_filtered, columns=top_features)
X_val_filtered_df = pd.DataFrame(X_val_filtered, columns=top_features)

xgb_model_filtered.fit(
    X_train_filtered_df,
    xgb_data["y_train"],
    eval_set=(X_val_filtered_df, xgb_data["y_val"]),
    verbose=False,
)

print("XGBoost re-training finished!")

# Evaluate
preds = xgb_model_filtered.predict(X_test_filtered)
probs = xgb_model_filtered.predict_proba(X_test_filtered)[ :, 1]

# Generate plots
plot_confusion_matrix(xgb_data["y_test"], preds, model_name="xgboost_filtered")
plot_roc_curve(xgb_data["y_test"], probs, model_name="xgboost_filtered")

```

```

plot_xgboost_importance(xgb_model_filtered, model_name="xgboost_filtered")

# Compare with original (optional)
original_preds = xgb_model.predict(X_test_df)
original_probs = xgb_model.predict_proba(X_test_df)[:, 1]

results = {
    "Accuracy": accuracy_score(xgb_data["y_test"], preds),
    "F1-Score": f1_score(xgb_data["y_test"], preds),
    "Recall": recall_score(xgb_data["y_test"], preds),
    "ROC-AUC": roc_auc_score(xgb_data["y_test"], probs),
    "original_accuracy": accuracy_score(xgb_data["y_test"], original_preds),
    "features_used": n_keep,
    "features_dropped": len(dropped_features),
    "top_features": top_features,
}
if verbose:
    print("\nPerformance Comparison:")
    print(f"    Original Accuracy: {results['original_accuracy']:.4f}")
    print(f"    Filtered Accuracy: {results['Accuracy']:.4f}")
    improvement = results["Accuracy"] - results["original_accuracy"]
    print(f"    {'Improvement' if improvement > 0 else 'Slight decrease'}: {improvement:
+.4f}")

return results

```

Dlaczego:

- XGBoost ma wbudowaną regularyzację, ale zbędne cechy mogą:
 - wprowadzać szum,
 - powodować lekkie przetrenowanie,
 - wydłużać czas treningu.
- Usunięcie najmniej ważnych cech upraszcza model, zmniejsza wariancję i może poprawiać generalizację.
- Po ponownym trenowaniu często okazuje się, że model na mniejszej liczbie cech działa równie dobrze lub lepiej.